Dự đoán giá nhà đất/bất động sản bằng các mô hình máy học

Đỗ Nguyễn Thanh Phong, Trịnh Minh Toàn, Dương Chí Khang, Cao Thanh Tài

Giới thiệu

Xác định vấn đề:

- Input: Danh sách liệt kê thông tin và giá của các bất động sản hiện có
- Output: Dự đoán giá cả của các bất động sản trong tương lai

Thách thức:

Xử lý và mô hình hóa một tập dữ liệu có nhiều đặc trưng hỗn hợp (số, phân loại, thứ bậc) với quan hệ phi tuyến phức tạp giữa các yếu tố ảnh hưởng đến giá nhà.

Biến thứ bậc / chất lượng

OverallQual	Chất lượng tổng thể (1–10)
OverallCond	Tình trạng tổng thể (1–10)
ExterQual	Chất lượng ngoại thất
ExterCond	Tình trạng ngoại thất
BsmtQual	Chất lượng tầng hầm
BsmtCond	Tình trạng tầng hầm
HeatingQC	Chất lượng hệ thống sưởi
KitchenQual	Chất lượng bếp
FireplaceQu	Chất lượng lò sưởi
GarageQual	Chất lượng gara
GarageCond	Tình trạng gara
PoolQC	Chất lượng hồ bơi

Biến thời gian

YearBuilt	Năm xây dựng
YearRemodAdd	Năm sửa chữa hoặc cải tạo
YrSold	Năm bán nhà

Biến SalePrice là biến quyết định của bộ dữ liệu

Quy trình đề xuất

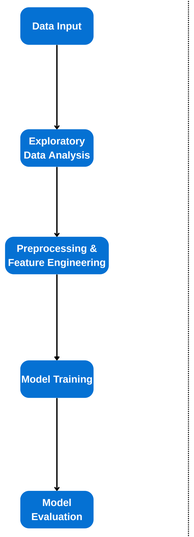

Dữ liệu

- Số lượng: 1460 bản ghi (training set), 1461 bản ghi (testing set), có tổng cộng 80 thuộc tính
- Nguồn dữ liệu: Kaggle – *House Prices - Advanced Regression Techniques*

Biến định lượng:

LotFrontage	Chiều dài mặt tiền lô đất (feet)
LotArea	Diện tích lô đất (feet vuông)
MasVnrArea	Diện tích ốp tường ngoài (feet²)
BsmtFinSF1	Diện tích hoàn thiện tầng hầm loại 1
BsmtFinSF2	Diện tích hoàn thiện tầng hầm loại 2
BsmtUnfSF	Diện tích tầng hầm chưa hoàn thiện
TotalBsmtSF	Tổng diện tích tầng hầm
1stFlrSF	Diện tích tầng 1
2ndFlrSF	Diện tích tầng 2
LowQualFinSF	Diện tích hoàn thiện chất lượng thấp
GrLivArea	Tổng diện tích sinh hoạt trên mặt đất
BsmtFullBath	Số phòng tắm đầy đủ ở tầng hầm
BsmtHalfBath	Số phòng tắm nhỏ ở tầng hầm
FullBath	Số phòng tắm đầy đủ trên mặt đất
HalfBath	Số phòng tắm nhỏ trên mặt đất
BedroomAbvGr	Số phòng ngủ trên mặt đất
KitchenAbvGr	Số bếp trên mặt đất
TotRmsAbvGrd	Tổng số phòng (không tính tầng hầm)
Fireplaces	Số lò sưởi
GarageYrBlt	Năm xây gara
GarageCars	Số chỗ để xe trong gara
GarageArea	Diện tích gara
WoodDeckSF	Diện tích sàn gỗ ngoài trời
OpenPorchSF	Diện tích hiên mở
EnclosedPorch	Diện tích hiên kín
3SsnPorch	Diện tích hiên 3 mùa
ScreenPorch	Diện tích hiên có lưới
PoolArea	Diện tích hồ bơi
MiscVal	Giá trị đặc điểm phụ
MoSold	Tháng bán nhà (1–12)
MSSubClass	Mã loại nhà (được mã hóa bằng số)

Biến phân loại:

MSZoning	Phân loại khu quy hoạch
Street	Loại đường tiếp cận
Alley	Loại ngõ hoặc hẻm
LotShape	Hình dạng lô đất
LandContour	Độ bằng phẳng của địa hình
Utilities	Hệ thống hạ tầng
LotConfig	Cấu hình lô đất
LandSlope	Độ dốc của đất
Neighborhood	Khu dân cư
Condition1	Vị trí liên quan đến đường chính
Condition2	Vị trí phụ
BldgType	Kiểu công trình
HouseStyle	Kiểu thiết kế
RoofStyle	Kiểu mái
RoofMatl	Vật liệu mái
Exterior1st	Vật liệu ngoài chính
Exterior2nd	Vật liệu ngoài phụ
MasVnrType	Loại vật liệu ốp tường
Foundation	Loại móng nhà
BsmtExposure	Mức độ thoáng sáng tầng hầm
BsmtFinType1	Loại hoàn thiện tầng hầm 1
BsmtFinType2	Loại hoàn thiện tầng hầm 2
Heating	Hệ thống sưởi
CentralAir	Có điều hòa trung tâm không
Electrical	Hệ thống điện
Functional	Chức năng tổng thể
GarageType	Loại gara
GarageFinish	Mức độ hoàn thiện gara
PavedDrive	Đường vào nhà lát nhựa
Fence	Loại hàng rào
MiscFeature	Đặc điểm phụ
SaleType	Loại giao dịch
SaleCondition	Tình trạng bán

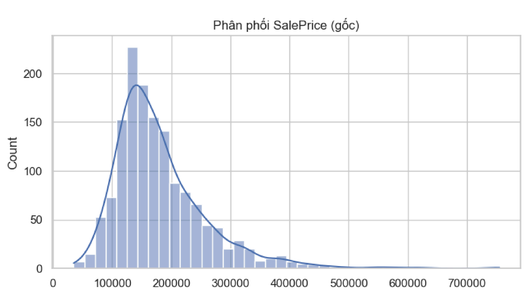

Phân tích khám phá dữ liệu

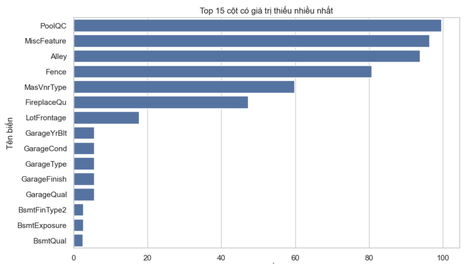

	Missing Count	Missing Percent
PoolQC	1453	9.952
MiscFeature	1406	9.630
Alley	1369	9.377
Fence	1179	8.075
MasVnrType	872	5.973
FireplaceQu	690	4.726
LotFrontage	259	1.774
GarageYrBlt	81	555
GarageCond	81	555
GarageType	81	555
GarageFinish	81	555
GarageQual	81	555
BsmtFinType2	38	260
BsmtExposure	38	260
BsmtQual	37	253
BsmtCond	37	253
BsmtFinType1	37	253
MasVnrArea	8	55
Electrical	1	7

Tiền xử lý dữ liệu và Kỹ thuật tạo đặc trưng

Xử lý dữ liệu thiếu:

- Điền các giá trị NA bằng None ở các cột : 'PoolQC', 'MiscFeature', 'Alley', 'Fence', 'FireplaceQu', 'GarageType', 'GarageFinish', 'GarageQual', 'GarageCond','BsmtQual', 'BsmtCond', 'BsmtExposure', 'BsmtFinType1', 'BsmtFinType2'.
- Điền các giá trị NA bằng 0 ở các cột : 'GarageYrBlt', 'GarageArea', 'GarageCars','BsmtFinSF1', 'BsmtFinSF2', 'BsmtUnfSF', 'TotalBsmtSF', 'BsmtFullBath', 'BsmtHalfBath'.
- Điền theo nhóm (LotFrontage theo Neighborhood) : `LotFrontage` ; điền theo trung vị trong khu vực.
- Các cột phân loại còn lại dùng mode.

Kỹ thuật tạo đặc trưng và chuẩn hóa:

Nhóm biến	Phương pháp mã hóa	Ví dụ biến	Cách chuyển đổi / Quy tắc	Mục tiêu	Nhóm biến
Biến thứ tự (Ordinal)	Ordinal Mapping	ExterQual, KitchenQual, FireplaceQu, GarageCond, PoolQC	Chuyển đổi thang chất lượng: Ex=5, Gd=4, TA=3, Fa=2, Po=1, None=0	Giúp mô hình hiểu **thứ tự tốt–xấu** giữa các giá trị	**Biến thứ tự (Ordinal)**
Biến thứ tự đặc biệt	Custom Mapping	BsmtExposure, LandSlope, LotShape, PavedDrive, Utilities	Tạo mapping riêng theo mức độ (ví dụ: Gtl>Mod>Sev hoặc Y>P>N)	Bảo toàn **mối quan hệ thứ bậc thực tế** giữa các mức	**Biến thứ tự đặc biệt**
Biến danh nghĩa (Nominal)	One-Hot Encoding	Neighborhood, BldgType, HouseStyle, Exterior1st, MSZoning	Tạo cột nhị phân (0/1) cho từng giá trị, dùng pd.get_dummies(drop_first=True)	Biến dữ liệu **phân loại rời rạc** thành dạng số	**Biến danh nghĩa (Nominal)**
Biến số nhưng thực chất là danh nghĩa	Ép kiểu sang chuỗi (str)	MSSubClass	Chuyển kiểu dữ liệu từ số sang chuỗi trước khi mã hóa	Xử lý chính xác biến dạng **mã phân loại**	**Biến số nhưng thực chất là danh nghĩa**

Huấn luyện và đánh giá mô hình

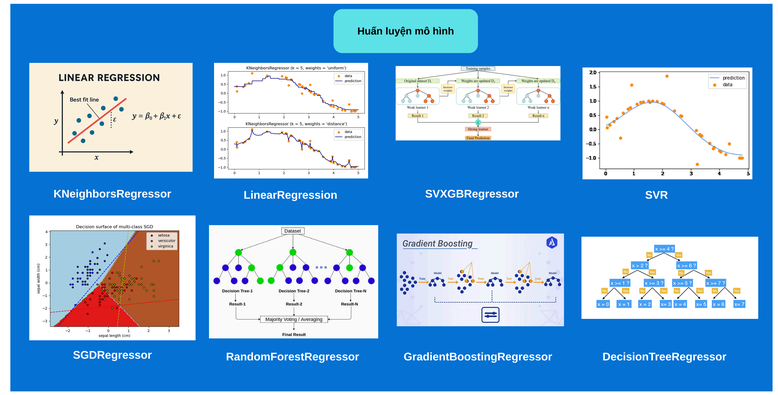

K-Fold Cross-Validation

Đánh giá mô hình

Train-Test Split Evalution

Thực nghiệm

TN1 - Sử dụng Train/Test Split Evaluation:

Model	Accuracy	F1_Weighted	ROC_AUC
KNeighbors	0,800	0,800	0,936
RandomForest	0,728	0,727	0,903
GradientBoosting	0,728	0,727	0,900
DecisionTree	0,640	0,636	0,730
LogisticRegression	0,688	0,687	0,837
SGDClassifier	0,608	0,606	NaN
SVR	**0,808**	**0,807**	**0,941**
XGB	0,776	0,775	0,910

TN2 - Sử dụng K-Fold Cross-Validation:

Model	Accuracy	F1_Weighted	ROC_AUC
KNeighbors	0,750	0,751	0,892
RandomForest	0,730	0,727	0,877
GradientBoosting	0,690	0,693	0,853
DecisionTree	0,590	0,587	0,690
LogisticRegression	0,700	0,701	0,848
SGDClassifier	0,620	0,615	NaN
SVR	**0,800**	**0,800**	**0,919**
XGB	0,720	0,720	0,854

Mô hình tốt nhất sau cùng là **Support Vector Regression (SVR)**

Kết quả

Khi thực hiện chạy trên Kaggle, kết quả thu được là: