

# Dự đoán giá nhà bằng các mô hình máy học

Đỗ Nguyễn Thanh Phong, Dương Chí Khang, Trịnh Minh Toàn, Cao Thanh Tài





# Agenda

1. Introduction
2. Related works
3. Proposed method
4. Experiment and Results
5. Conclusion

# 1. Introduction

Input: Bộ đặc trưng mô tả ngôi nhà



Model


Output: Giá nhà

34900 - 755000đô

# 1. Introduction

Bộ dữ liệu gồm 79 đặc trưng


|             |                                                          |
|-------------|----------------------------------------------------------|
| SalePrice   | Giá bán bất động sản tính bằng đô la.<br>(Biến Mục Tiêu) |
| MSSubClass  | Lớp xây dựng                                             |
| MSZoning    | Phân loại phân vùng chung                                |
| LotArea     | Diện tích lô đất tính bằng feet vuông                    |
| Đường phố   | Loại đường đi vào                                        |
| Hẻm         | Loại lối vào hẻm                                         |
| LotShape    | Hình dạng chung của bất động sản                         |
| LandContour | Độ phẳng của bất động sản                                |
| Tiện ích    | Loại tiện ích có sẵn                                     |



## 2. Related Work


### Thuật toán sử dụng

KNeighborsRegressor




LinearRegression

### LINEAR REGRESSION



## 2. Related Work


### DecisionTreeRegressor






## 2. Related Work

GradientBoostingRegressor




RandomForestRegressor




## 2. Related Work

SGDRegressor




SVR






## 2. Related Work

### SVXGBRegressor



### 3. Proposed methods





### 3. Proposed methods

## Phân tích và khám phá dữ liệu


Dữ liệu bị lệch trái

Đa số nhà có giá từ

100.000 - 200.000 đô

Giá nhà trải dài từ

30.000 - hơn 700.000 đô



# 3. Proposed methods

## Phân tích và khám phá dữ liệu

Có nhiều giá trị thiếu

- Nhóm thiếu hoàn toàn (>90%):


- PoolQC, MiscFeature, Alley
  - → Thực tế: Không có hồ bơi, không có tính năng đặc biệt, không có ngõ hẻm

- Nhóm thiếu nhiều (50-90%):

- Fence, FireplaceQu
  - → Thực tế: Không có hàng rào, không có lò sưởi

- Nhóm thiếu trung bình (10-30%):


- LotFrontage, Garage-related features
  - Basement-related features



# 3. Proposed methods

Các biến có tương quan MẠNH với SalePrice ( $|r| > 0.6$ ):

- `OverallQual` (0.79): - Chất lượng tổng thể là yếu tố quan trọng nhất
- `GrLivArea` (0.71): - Diện tích sinh hoạt ảnh hưởng lớn đến giá
- `GarageCars` (0.64): - Số chỗ đỗ garage thể hiện đẳng cấp bất động sản
- `GarageArea` (0.62): - Diện tích garage tỷ lệ thuận với giá nhà
- `TotalBsmtSF` (0.61): - Diện tích tầng hầm phản ánh quy mô
- `1stFlrSF` (0.61): - Diện tích tầng 1 có tác động đáng kể





### 3. Proposed methods

#### Điền giá trị thiếu

- Điền các giá trị NA bằng None ở các cột : 'PoolQC', 'MiscFeature', 'Alley', 'Fence', 'FireplaceQu', 'GarageType', 'GarageFinish', 'GarageQual', 'GarageCond', 'BsmtQual', 'BsmtCond', 'BsmtExposure', 'BsmtFinType1', 'BsmtFinType2'.
- Điền các giá trị NA bằng 0 ở các cột : 'GarageYrBlt', 'GarageArea', 'GarageCars', 'BsmtFinSF1', 'BsmtFinSF2', 'BsmtUnfSF', 'TotalBsmtSF', 'BsmtFullBath', 'BsmtHalfBath'.
- Điền theo nhóm (LotFrontage theo Neighborhood) : `LotFrontage` ; điền theo trung vị trong khu vực.
- Các cột phân loại còn lại dùng mode.

# 3. Proposed methods

## Kỹ thuật chọn đặc trưng và chuẩn hóa

| Nhóm biến                                    | Phương pháp mã hóa              | Ví dụ biến                                                | Cách chuyển đổi / Quy tắc                                                     | Mục tiêu                                                 | Nhóm biến                                    |
|----------------------------------------------|---------------------------------|-----------------------------------------------------------|-------------------------------------------------------------------------------|----------------------------------------------------------|----------------------------------------------|
| <b>Biến thứ tự (Ordinal)</b>                 | <b>Ordinal Mapping</b>          | ExterQual, KitchenQual, FireplaceQu, GarageCond, PoolQC   | Chuyển đổi thang chất lượng: Ex=5, Gd=4, TA=3, Fa=2, Po=1, None=0             | Giúp mô hình hiểu <b>thứ tự tốt-xấu</b> giữa các giá trị | <b>Biến thứ tự (Ordinal)</b>                 |
| <b>Biến thứ tự đặc biệt</b>                  | <b>Custom Mapping</b>           | BsmtExposure, LandSlope, LotShape, PavedDrive, Utilities  | Tạo mapping riêng theo mức độ (ví dụ: Gtl>Mod>Sev hoặc Y>P>N)                 | Bảo toàn <b>mối quan hệ thứ bậc thực tế</b> giữa các mức | <b>Biến thứ tự đặc biệt</b>                  |
| <b>Biến danh nghĩa (Nominal)</b>             | <b>One-Hot Encoding</b>         | Neighborhood, BldgType, HouseStyle, Exterior1st, MSZoning | Tạo cột nhị phân (0/1) cho từng giá trị, dùng pd.get_dummies(drop_first=True) | Biến dữ liệu <b>phân loại rời rạc</b> thành dạng số      | <b>Biến danh nghĩa (Nominal)</b>             |
| <b>Biến số nhưng thực chất là danh nghĩa</b> | <b>Ép kiểu sang chuỗi (str)</b> | MSSubClass                                                | Chuyển kiểu dữ liệu từ số sang chuỗi trước khi mã hóa                         | Xử lý chính xác biến dạng <b>mã phân loại</b>            | <b>Biến số nhưng thực chất là danh nghĩa</b> |

### 3. Proposed methods

Kỹ thuật chọn đặc trưng và chuẩn hóa

⇒ Tóm lại:

- Mã hóa ordinal cho các biến chất lượng
- One-hot encoding cho biến phân loại còn lại
- Dùng `get_dummies` cho tất cả các cột 'object' còn lại




# 3. Proposed methods

## Đánh giá mô hình

Đánh giá bằng K-Fold Cross-Validation:

- Là một kỹ thuật tiêu chuẩn dùng để đánh giá hiệu suất và độ ổn định của một mô hình máy học.
- Mục đích chính của nó là để có được một ước tính đáng tin cậy về khả năng tổng quát hóa của mô hình trên dữ liệu mới, chưa từng thấy, đồng thời giúp phát hiện các vấn đề như quá khớp (overfitting).




### 3. Proposed methods

## Đánh giá mô hình

Đánh giá bằng Train-Test Split Evalution:

- Là một kỹ thuật đánh giá mô hình đơn giản và phổ biến nhất trong máy học.
- Nó chia tập dữ liệu ban đầu của bạn thành hai phần riêng biệt: Training Set (Thường chiếm phần lớn dữ liệu, ví dụ: 70% - 80%) và Testing Set (Là phần dữ liệu còn lại, ví dụ: 20% - 30%)
- Mục đích chính là để đánh giá hiệu suất tổng quát hóa của mô hình, thông qua đánh giá hiệu suất của mô hình trên 1 tập validation riêng biệt sau khi huấn luyện phần còn lại trước đó.



## 4. Experience and result

### Kết quả khi dùng Train/Test Split Evaluation:

| Model              | Accuracy     | F1_Weighted     | ROC_AUC        |
|--------------------|--------------|-----------------|----------------|
| KNeighbors         | 0.8          | 0.79966         | 0.935926       |
| RandomForest       | 0.728        | 0.727054        | 0.902742       |
| GradientBoosting   | 0.728        | 0.726893        | 0.899805       |
| DecisionTree       | 0.64         | 0.635707        | 0.729991       |
| LogisticRegression | 0.688        | 0.686765        | 0.837076       |
| SGDClassifier      | 0.608        | 0.605768        | NaN            |
| <b>SVR</b>         | <b>0.808</b> | <b>0.807429</b> | <b>0.94052</b> |
| XGB                | 0.776        | 0.77515         | 0.910234       |



## 4. Experience and result

### Kết quả khi dùng K-Fold Cross-Validation:

| Model              | Accuracy    | F1_Weighted  | ROC_AUC      |
|--------------------|-------------|--------------|--------------|
| KNeighbors         | 0.75        | 0.751        | 0.892        |
| RandomForest       | 0.73        | 0.727        | 0.877        |
| GradientBoosting   | 0.69        | 0.693        | 0.853        |
| DecisionTree       | 0.59        | 0.587        | 0.690        |
| LogisticRegression | 0.70        | 0.701        | 0.848        |
| SGDClassifier      | 0.62        | 0.615        | NaN          |
| <b>SVR</b>         | <b>0.80</b> | <b>0.800</b> | <b>0.919</b> |
| XGB                | 0.72        | 0.720        | 0.854        |

## 5. Conclusion

Qua quá trình huấn luyện và đánh giá, chúng ta thấy mô hình **SVM** có độ chính xác cao nhất, điểm ROC AUC đạt cao nhất trong tất cả mô hình. Mặc dù trong quá trình huấn luyện có gặp chút trục trặc, nhưng xét về tính phù hợp và ổn định, **SVM** có kết quả ổn định nhất, trở thành lựa chọn tối ưu cho việc dự đoán giá nhà trong tương lai



**submission.csv**

Complete · 31s to go

**0.14473**





# Thank You All

---