

Dự đoán và phân loại các thể loại âm nhạc cho các bài hát bằng các mô hình máy học

Đỗ Nguyễn Thanh Phong, Dương Chí Khang, Trịnh Minh Toàn, Cao Thanh Tài

*Tác giả liên hệ. E-mail(s): 3123410260@sv.sgu.edu.vn

Các tác giả đóng góp: 3123410148@sv.sgu.edu.vn,
3123410383@sv.sgu.edu.vn, 3123410312@sv.sgu.edu.vn

*Các tác giả này có đóng góp ngang nhau cho công trình.

Tóm tắt

Trong kỷ nguyên số hóa, sự bùng nổ của các nền tảng phát trực tuyến (streaming) đã tạo ra một kho tàng dữ liệu âm nhạc khổng lồ, đặt ra thách thức lớn cho việc tổ chức và truy xuất thông tin. Việc phân loại thủ công hàng triệu bài hát không chỉ tốn kém thời gian mà còn mang tính chủ quan cao. Nghiên cứu này tập trung giải quyết bài toán phân loại thể loại âm nhạc tự động (Music Genre Classification) – một bài toán cốt lõi trong các hệ thống gợi ý bài hát hiện đại. Dựa trên tập dữ liệu từ cuộc thi Kaggle SHAI bao gồm 11 thể loại nhạc khác nhau, chúng tôi đề xuất một quy trình xử lý dữ liệu toàn diện nhằm giải quyết các vấn đề về nhiễu và mất cân bằng. Điểm đóng góp chính của nghiên cứu là việc áp dụng kỹ thuật biến đổi Logarit (Log Transformation) để chuẩn hóa đặc trưng thời lượng bài hát và chiến lược điền khuyết dữ liệu lai (Hybrid Imputation). Mô hình huấn luyện được sử dụng bao gồm KNN, Random Forest, XGBoost, Naive Bayes.

Từ khóa: mô hình huấn luyện, thể loại âm nhạc, phân loại, streaming, kỹ thuật biến đổi

1. Giới thiệu

Âm nhạc không chỉ là nghệ thuật mà còn là những con số. Đằng sau giai điệu của một bản nhạc Pop hay sự mạnh mẽ của một bản Rock là các thông số kỹ thuật có thể đo lường được như nhịp độ (tempo), độ ồn (loudness), hay mức độ "mộc" (acousticness). Tuy nhiên, ranh giới giữa các dòng nhạc thường rất mờ nhạt và chồng lấn lên nhau, khiến cho việc phân loại trở thành một bài toán học máy phức tạp (Multi-class Classification).

Tương tự như bài toán dự đoán khả năng sống sót trên tàu Titanic là bài toán kinh điển cho phân loại nhị phân, bài toán phân loại âm nhạc này là đại diện tiêu biểu cho phân loại đa lớp với dữ liệu thực tế nhiều nhiễu. Thách thức lớn nhất mà nghiên cứu phải đối mặt bao gồm: (1) Sự không đồng nhất trong đơn vị đo lường của dữ liệu thô; (2) Sự tồn tại của các giá trị ngoại lai (outliers) cực đoan; và (3) Sự mất cân bằng nghiêm trọng giữa các lớp dữ liệu (Class Imbalance). Mục tiêu của bài báo này là xây dựng một quy trình tiền xử lý dữ liệu mạnh mẽ và một mô hình dự đoán có khả năng tổng quát hóa cao, giảm thiểu rủi ro học vẹt (overfitting).

2. Dữ liệu và Phương pháp nghiên cứu

2.1. Mô tả dữ liệu:

Nghiên cứu sử dụng tập dữ liệu "Music Genre Classification" bao gồm 14,396 mẫu huấn luyện và 3,600 mẫu kiểm thử. Dữ liệu bao gồm 11 nhãn lớp (thể loại nhạc) và 18 đặc trưng ban đầu. Quá trình tiền xử lý dữ liệu được thực hiện nghiêm ngặt để giải quyết các vấn đề về nhiễu và định dạng:

Xử lý ngoại lai và chuẩn hóa đơn vị: Đặc trưng `duration_in_min/ms` được phát hiện chứa hỗn hợp đơn vị phút và mili-giây. Dữ liệu được đồng bộ hóa về mili-giây, sau đó áp dụng biến đổi Logarit tự nhiên để nén dải giá trị:

Việc này giúp giảm thiểu tác động của các bài hát có độ dài bất thường lên mô hình.

-Xử lý dữ liệu thiếu: Áp dụng chiến lược lai (Hybrid Imputation): điền giá trị 0 cho `instrumentalness` và giá trị trung vị (Median) cho `Popularity` và `key`.

-Chuẩn hóa đặc trưng (Feature Scaling): Sử dụng `StandardScaler` để đưa dữ liệu về phân phối chuẩn với trung bình $\mu = 0$ và độ lệch chuẩn $\sigma = 1$.

2.2. Các mô hình thuật toán

Nghiên cứu tập trung đánh giá và tối ưu hóa ba thuật toán học máy đại diện:

a) *K-Nearest Neighbors (KNN)*

KNN là thuật toán học dựa trên trường hợp, phân loại một điểm dữ liệu mới dựa trên đa số phiếu bầu từ k láng giềng gần nhất. Hàm khoảng cách Euclidean được sử dụng để đo độ tương đồng giữa hai điểm dữ liệu x và y trong không gian n chiều:

$$d(x,y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Tham số quan trọng được tối ưu hóa: số lượng láng giềng k và trọng số khoảng cách (weights).

b) *Random Forest Classifier*

Random Forest là phương pháp học kết hợp (Ensemble) dạng Bagging, xây dựng nhiều cây quyết định (Decision Trees) trên các tập con dữ liệu khác nhau. Độ tinh khiết của nút phân chia được đo lường bằng chỉ số Gini Impurity:

$$Gini(t) = 1 - \sum_{i=1}^C (p_i)^2$$

Trong đó p_i là xác suất của lớp i tại nút t. Kết quả cuối cùng được quyết định bằng cơ chế bỏ phiếu đa số từ các cây thành phần.

c. XGBoost (Extreme Gradient Boosting)

XGBoost là thuật toán thuộc họ Boosting, xây dựng mô hình theo phương pháp cộng dồn, trong đó mỗi cây mới được tạo ra để sửa lỗi của các cây trước đó. Hàm mục tiêu (Objective Function) tại bước thứ t được tối ưu hóa dựa trên khai triển Taylor bậc hai:

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^n [l(y_i, \hat{y}_i^{(t-1)}) + g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i)] + \Omega(f_t)$$

Trong đó g_i và h_i lần lượt là đạo hàm bậc nhất và bậc hai của hàm mất mát. XGBoost nổi bật với khả năng xử lý dữ liệu thưa và tránh overfitting nhờ thành phần điều chuẩn $\Omega(f_t)$.

d. Naive Bayes Classifier (Gaussian Naive Bayes)

Đây là thuật toán phân loại dựa trên xác suất, áp dụng Định lý Bayes với giả định "ngây thơ" rằng các đặc trưng đầu vào là hoàn toàn độc lập với nhau. Đối với dữ liệu âm nhạc liên tục đã qua chuẩn hóa, biến thể Gaussian được sử dụng. Nhãn dự đoán $\hat{y}$ được xác định bằng cách chọn lớp có xác suất hậu nghiệm cao nhất:

$$\hat{y} = \arg \max_y P(y) \prod_{i=1}^n P(x_i|y)$$

Trong đó $P(y)$ là xác suất tiên nghiệm của lớp y , và xác suất có điều kiện $P(x_i|y)$ được tính theo hàm mật độ xác suất của phân phối chuẩn (Gaussian):

$$P(x_i|y) = \frac{1}{\sqrt{2\pi\sigma_y^2}} \exp\left(-\frac{(x_i - \mu_y)^2}{2\sigma_y^2}\right)$$

Với μ_y và σ_y^2 lần lượt là trung bình và phương sai của đặc trưng x_i trong lớp y .

2.3. Các chỉ số đánh giá

Để đánh giá hiệu năng mô hình trên tập dữ liệu đa lớp bị mất cân bằng, chúng tôi sử dụng các chỉ số:

- **F1-Score (Macro Average):** Trung bình điều hòa giữa Precision và Recall, tính trung bình không trọng số trên tất cả các lớp:

$$F1_{macro} = \frac{1}{N} \sum_{i=1}^N 2 \cdot \frac{Precision_i \cdot Recall_i}{Precision_i + Recall_i}$$

- **ROC-AUC Score:** Diện tích dưới đường cong ROC, đánh giá khả năng phân tách giữa các lớp của mô hình.

$$AUC_{macro} = \frac{1}{C} \sum_{i=1}^C AUC_i$$

3. Thực nghiệm và Kết quả

3.1. Thiết lập thực nghiệm

Quá trình thực nghiệm được thực hiện trên ngôn ngữ Python sử dụng thư viện Scikit-learn. Để đảm bảo tính khách quan và tìm ra bộ tham số tối ưu (Best Parameters), chúng tôi sử dụng phương pháp tìm kiếm lưới Grid Search kết hợp với kiểm định chéo Stratified K-Fold Cross-Validation (với k=5). Điều này đảm bảo tỉ lệ các lớp trong các tập fold luôn được giữ nguyên như tập dữ liệu gốc.



3.2. Trình bày kết quả

a. So sánh hiệu năng giữa các mô hình Bảng dưới đây tổng hợp kết quả đánh giá tốt nhất của từng mô hình sau khi tinh chỉnh siêu tham số trên tập kiểm thử (Test Set):

Mô hình	Accuracy (Độ chính xác)	F1-Score (Macro)	Nhận xét
KNN	0.4919	0.4482	Hiệu năng thấp, không phù hợp với dữ liệu nhiều chiều.
Naive Bayes	0.4808	0.4226	Kết quả thấp nhất, mô hình quá đơn giản.
Random Forest	0.7542	0.6648	Độ chính xác cao nhất, hoạt động rất ổn định.
XGBoost	0.7172	0.6652	F1-Score cao nhất, xử lý tốt dữ liệu mất cân bằng.

Bảng 1. Kết quả trung bình (mean) khi dùng K-Fold Cross-validation

b. Phân tích chi tiết

Dựa trên kết quả thực nghiệm, chúng tôi có các nhận định sau:


Sự thống trị của các mô hình cây quyết định (Tree-based Models): Cả Random Forest và XGBoost đều cho thấy hiệu năng vượt trội so với các thuật toán truyền thống như KNN hay Naive Bayes. Cụ thể, Random Forest đạt độ chính xác ấn tượng lên tới 75.42%, cao hơn KNN gần 26%. Điều này chứng tỏ cấu trúc dữ liệu âm nhạc phù hợp với cách phân chia không gian đặc trưng của các mô hình cây.

So sánh giữa Random Forest và XGBoost: Đây là cuộc đua song mã rất sát sao.

Random Forest dẫn đầu về Accuracy (75.42%), cho thấy mô hình này có khả năng dự đoán đúng tổng thể tốt nhất. Bản chất Bagging của Random Forest giúp giảm phương sai và chống nhiễu hiệu quả trên tập dữ liệu này.

Tuy nhiên, XGBoost lại nhỉnh hơn một chút về chỉ số F1-Score (0.6652 so với 0.6648). Trong bài toán phân loại đa lớp có sự mất cân bằng dữ liệu, F1-Score phản ánh trung thực hơn khả năng của mô hình. Điều này cho thấy XGBoost có ưu thế nhẹ trong việc cân bằng giữa độ chính xác (Precision) và độ phủ (Recall), đặc biệt là với các thể loại nhạc ít phổ biến.

Hạn chế của KNN và Naive Bayes: Hai mô hình này chỉ đạt độ chính xác dưới 50%. KNN dường như bị ảnh hưởng bởi "lời nguyền số chiều" (curse of dimensionality) dù đã qua xử lý dữ liệu, trong khi Naive Bayes quá đơn giản với giả định các đặc trưng độc lập, không nắm bắt được mối quan hệ phức tạp giữa các thông số âm thanh.



Phân tích kết quả

Từ Bảng 1, cục diện đã thay đổi thú vị khi **Random Forest** vươn lên dẫn đầu về chỉ số Accuracy (**0.7542**), vượt qua XGBoost (**0.7172**). Điều này cho thấy với bộ dữ liệu này, cơ chế Bagging của Random Forest hoạt động cực kỳ hiệu quả trong việc giảm phương sai và đưa ra dự đoán chính xác tổng thể (Overall Accuracy) tốt nhất.

Tuy nhiên, khi xét đến chỉ số F1-Score (Macro) – thước đo quan trọng cho dữ liệu mất cân bằng, **XGBoost** vẫn giữ vững vị thế số một với **0.6652**, nhỉnh hơn một chút so với Random Forest (0.6648). Sự chênh lệch rất nhỏ này minh chứng rằng XGBoost có khả năng cân bằng tốt hơn giữa độ chính xác (Precision) và độ phủ (Recall), đặc biệt là trong việc nhận diện các thể loại nhạc hiếm gặp (Minority Classes).

Về phía **KNN**, mô hình này cho thấy hiệu năng thấp nhất trong ba thuật toán được thử nghiệm, với Accuracy chỉ đạt **0.4919** và F1-Score đạt **0.4482**. Kết quả này thấp hơn đáng kể so với nhóm mô hình cây quyết định (Tree-based models). Nguyên nhân có thể do KNN nhạy cảm với không gian dữ liệu nhiều chiều và nhiễu, trong khi Random Forest và XGBoost lại có cơ chế chọn lọc đặc trưng (Feature Selection) nội tại giúp chúng vượt qua trở ngại này dễ dàng.

Quan sát sự ổn định của mô hình (thông qua quá trình Validation trước đó và kết quả Test thực tế), có thể khẳng định rằng nhóm thuật toán cây quyết định (**Random Forest và XGBoost**) là lựa chọn tối ưu và đáng tin cậy nhất cho bài toán này, bỏ xa hiệu quả của các phương pháp dựa trên khoảng cách như KNN.

4. Kết luận

Nghiên cứu đã thực hiện so sánh toàn diện bốn thuật toán học máy trên bài toán phân loại thể loại âm nhạc. Kết quả thực nghiệm khẳng định rằng **Random Forest** và **XGBoost** là hai lựa chọn hàng đầu. Trong khi Random Forest mang lại độ chính xác tổng thể cao nhất (75.42%), thì XGBoost lại chứng tỏ sự tinh tế trong việc tối ưu hóa F1-Score (0.6652).

Từ kết quả này, nhóm nghiên cứu đề xuất sử dụng **Random Forest** nếu ưu tiên sự đơn giản và độ chính xác tổng quát, hoặc **XGBoost** nếu bài toán yêu cầu sự khắt khe hơn trong việc phân loại các lớp thiểu số. Hướng phát triển tiếp theo có thể là kết hợp cả hai mô hình này (Ensemble Learning) để tận dụng ưu điểm của cả hai, nhằm đẩy độ chính xác lên mức cao hơn nữa.

References

- [1] Pedregosa, F., et al. (2011). "Scikit-learn: Machine learning in Python." *Journal of Machine Learning Research*, 12, 2825-2830.
- [2] Chen, T., & Guestrin, C. (2016). "XGBoost: A Scalable Tree Boosting System." *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*.
- [3] Schedl, M., et al. (2014). "Music Information Retrieval: Recent Developments and Applications." *Foundations and Trends in Information Retrieval*.