PHÂN LOẠI THỂ LOẠI ÂM NHẠC CHO CÁC BÀI HÁT BẰNG CÁC MÔ HÌNH MÁY HỌC

Đỗ Nguyễn Thanh Phong, Trịnh Minh Toàn, Dương Chí Khang, Cao Thanh Tài

Giới thiệu

Xác định vấn đề:

- Input: Danh sách các bài hát kèm các đặ trưng của chúng
- Output: Dự đoán và phân loại thể loại của bài hát đó ((Rock, Pop, HipHop, Metal, Blues, Country, …)

Thách thức:

Xử lý và mô hình hóa một tập dữ liệu có nhiều đặc trưng hỗn hợp (số, phân loại, thứ bậc) với quan hệ phi tuyến phức tạp giữa các yếu tố ảnh hưởng đến giá nhà.

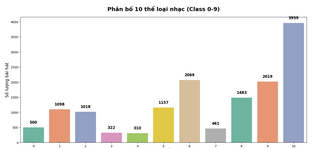

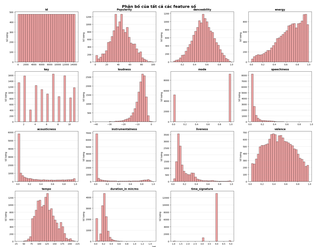

Dữ liệu

- *Số lượng*:14396 bản ghi (training set), 14397 bản ghi (testing set), có tổng cộng 18 thuộc tính
- Nguồn dữ liệu: Kaggle – *Music Genre Classification*

artist (artist name)	Tên nghệ sĩ — giúp biết ai hát bài đó
song (track name)	Tên bài hát — metadata.
popularity	Độ "phổ biến" của bài hát.
danceability	Một chỉ số đo mức độ "có thể nhảy được" của bài hát.
energy	Mức "năng lượng" — đo cường độ và hoạt động của bản nhạc.
key	Khóa chính (musical key) của bản nhạc — cho biết bài hát ở tông nào.
loudness	Độ lớn âm thanh — loudness trung bình của bài hát, đo bằng decibel (dB).
mode	Chế độ của bản nhạc: major hoặc minor (thường major = 1, minor = 0).
speechiness	Độ "nhiều lời nói/phát biểu" trong track — đo xem bản nhạc có chứa phần lời nói, nói chuyện, rap, speech hơn là hát/melodic.
acousticness	Mức độ "acoustic" — hay nói cách khác, độ "tự nhiên/không điện tử" của bản nhạc.
instrumentalness	Khả năng bản nhạc "không vocal" (không lời).
liveness	Đo xác suất bài hát được thu live — tức là xuất hiện khán giả, biểu diễn trực tiếp.
valence	Một chỉ số đo "tâm trạng/âm hưởng cảm xúc" của bài hát — "positiveness".
tempo	Tempo (nhịp độ) của bài — thường đo bằng BPM (beats per minute).
duration (in milliseconds)	Độ dài bài hát, tính theo mili-giây. Cho biết bài hát dài hay ngắn.
time signature	Nhịp (time signature) của bản nhạc — cho biết mỗi ô (measure) có bao nhiêu nhịp (beats), là cơ sở cho nhịp điệu, cấu trúc bài hát.
Class (label)	Nhãn (genre) — thể loại / thể nhạc mà bài hát được phân loại. Đây là target variable mà mô hình cần dự đoán.

Quy trình đề xuất

Phân tích khám phá dữ liệu

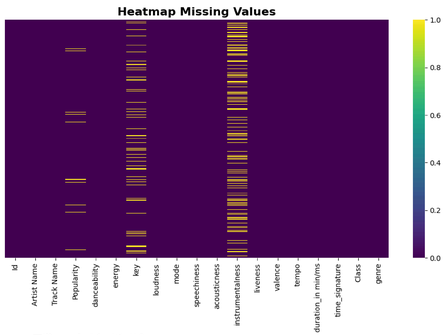

Tỷ lệ missing values (%):

Thuộc tính	Tỷ lệ thiếu (%)
instrumentalness	24.597110
key	11.176716
Popularity	2.313143

Tiền xử lý dữ liệu

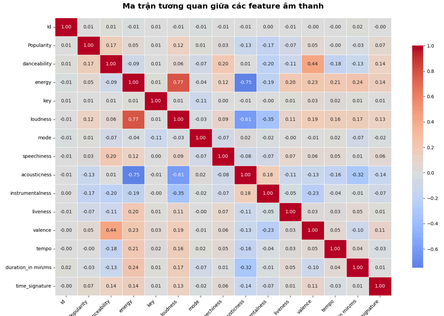

Xử lý dữ liệu thiếu:

- instrumentalness: Điền giá trị 0. (Giả định: thiếu dữ liệu = bài hát có lời).
- Các cột số (Popularity, key): Điền giá trị trung vị (Median) để tránh ảnh hưởng bởi ngoại lai.

Chuẩn hóa:

- Sử dụng StandardScaler: Đưa tất cả các đặc trưng về cùng một thang đo (mean=0, std=1). Theo đó, chúng ta fitting scaler trên tập Train và transform trên cả Train lẫn Test để tránh rò rỉ dữ liệu (Data Leakage).
- Chuẩn Hóa Đơn Vị Thời Gian (Duration):
  - Vấn đề: Cột duration_in min/ms bị lỗi, lẫn lộn giữa đơn vị phút và mili-giây.
  - Giải pháp: Áp dụng quy tắc: giá trị < 30 được coi là phút và quy đổi sang ms.
  - Tối ưu hóa: Sử dụng phép biến đổi Logarit (np.log1p) để xử lý phân phối lệch và giảm ảnh hưởng của các giá trị ngoại lai (bài hát quá dài).

Kỹ thuật tạo đặc trưng :

Loại bỏ các cột không mang tính định lượng hoặc không có ý nghĩa phân loại: 'Artist Name', 'Track Name'.

Huấn luyện và đánh giá mô hình

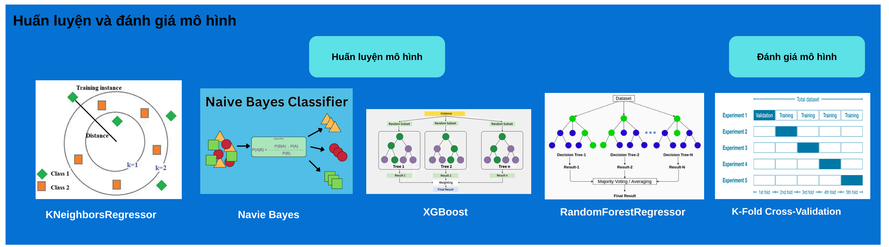

Thực nghiệm

TN1 - Huấn luyện tổng quan:

Model	Accuracy	F1_Weighted	ROC_AUC
K-Neighbors Nearest	3.807	3.765	7.408
Random Forest	4.523	4.147	8.526
Navie Bayes	3.821	3.485	8.316
XGBoost	**4.563**	**4.440**	**8.578**

TN2 - Huấn luyện sau cải thiện:

Model	Accuracy	F1_Weighted	ROC_AUC
K-Neighbors Nearest	4.919	4.482	NaN
Random Forest	7.542	6.648	NaN
Navie Bayes	4.808	4.226	NaN
XGBoost	**7.172**	**6.652**	**NaN**

Mô hình tốt nhất sau cùng là **XGBoost**

Kết quả
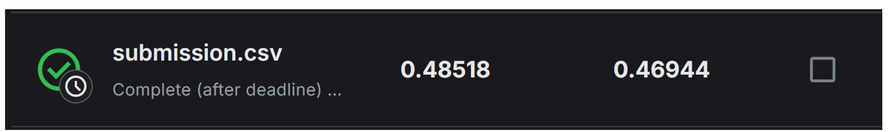
Khi thực hiện chạy trên Kaggle, kết quả thu được là: