Dự đoán khả năng sống sót của hành khách trên tàu Titanic bằng các mô hình máy học

Đỗ Nguyễn Thanh Phong, Trịnh Minh Toàn, Dương Chí Khang, Cao Thanh Tài

Giới thiệu

Xác định vấn đề:

- Input: Danh sách các hành khách gồm thông tin cá nhân và vé tàu
- Output: Xác suất hành khách sống sót hoặc thiệt mạng

Thách thức:

Dữ liệu không hoàn chỉnh, không đồng nhất giữa các biến, mất cân bằng dữ liệu, cần phải tiền xử lý và trích xuất đặc trưng hiệu quả

Dữ liệu

- Số lượng: 891 bản ghi (training set), 418 bản ghi (testing set)
- Nguồn dữ liệu: Kaggle – *Titanic: Machine Learning from Disaster*

PassengerId	ID hành khách
Survived	Trạng thái sống sót
Pclass	Hạng vé
Name	Tên hành khách
Sex	Giới tính
Age	Tuổi
SibSp	Số anh chị em/vợ chồng đi cùng
Parch	Số cha mẹ/con đi cùng
Ticket	Số vé
Fare	Giá vé
Cabin	Cabin
Embarked	Cảng đi

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

Quy trình đề xuất

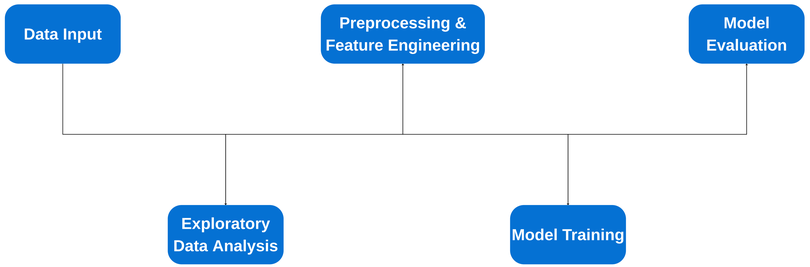

Phân tích khám phá dữ liệu

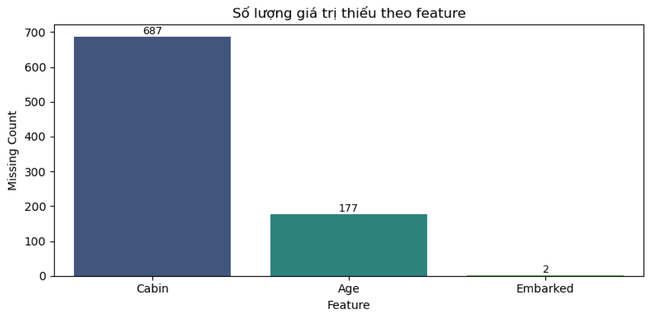

Tiền xử lý dữ liệu và Kỹ thuật tạo đặc trưng

Xử lý dữ liệu thiếu:

- Age: dùng median theo Title (dựa trên phân tích Name)
- Embarked: điền bằng mode
- Cabin: sử dụng Deck
- Age và Fare được chuẩn hóa bằng StandardScaler

Kỹ thuật tạo đặc trưng:

```
Data columns (total 12 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   PassengerId  891 non-null    int64
 1   Survived     891 non-null    int64
 2   Pclass       891 non-null    int64
 3   Name         891 non-null    object
 4   Sex          891 non-null    object
 5   Age          714 non-null    float64
 6   SibSp        891 non-null    int64
 7   Parch        891 non-null    int64
 8   Ticket       891 non-null    object
 9   Fare         891 non-null    float64
 10  Cabin        204 non-null    object
 11  Embarked     889 non-null    object
```

Tên cột mới	Ý nghĩa
Title	Tóm tắt tình trạng xã hội / độ tuổi/ giới tính gián tiếp (ví dụ: 'Master' thường là bé trai, 'Mrs' là phụ nữ đã kết hôn). Giúp phân biệt nhóm có tỷ lệ sống khác nhau.
FamilySize	Đánh giá quy mô gia đình trên tàu; ảnh hưởng tới khả năng sống (ví dụ gia đình lớn/cô lập).
IsAlone	Chỉ báo người đi một mình — thường tương quan với tỷ lệ sống khác so với người có gia đình.
Deck	Vị trí khoang (ký hiệu tầng/deck) đại diện cho vị trí cabin — ám chỉ mức tiện nghi/giá vé/khả năng tiếp cận thuyền cứu sinh.

Huấn luyện và đánh giá mô hình

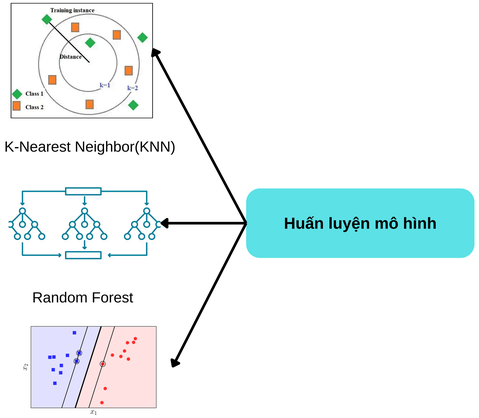

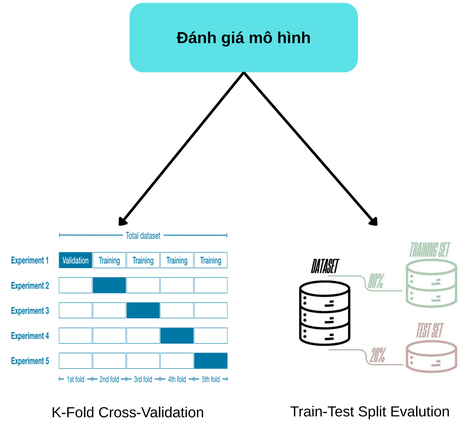

K-Fold Cross-Validation

Train-Test Split Evalution

Thực nghiệm

TN1 - Sử dụng Train/Test Split Evaluation:

Mô hình	Accuracy	F1-Score	ROC AUC
SVM	**0,8436**	**0,7879**	**0,8350**
RandomForest	0,7486	0,6763	0,8167
KNN	0,8212	0,7500	0,8403

TN2 - Sử dụng K-Fold Cross-Validation:

Mô hình	Accuracy	F1-Score	ROC AUC
SVM	0,8350	0,7742	0,8536
RandomForest	**0,8126**	**0,7489**	**0,8727**
KNN	0,8182	0,7484	0,8638

Mặc dù có 1 chút sai sót trong quá trình huấn luyện, nhưng mô hình tốt nhất sau cùng là ***Random Forest***

Kết quả

Khi thực hiện chạy trên Kaggle, kết quả thu được là: