

Dự đoán khả năng sống sót của hành khách trên tàu Titanic bằng các mô hình máy học

Đỗ Nguyễn Thanh Phong, Dương Chí Khang, Trịnh Minh Toàn, Cao Thanh Tài

*Tác giả liên hệ. E-mail(s): 3123410260@sv.sgu.edu.vn

Các tác giả đóng góp: 3123410148@sv.sgu.edu.vn,
3123410383@sv.sgu.edu.vn, 3123410312@sv.sgu.edu.vn

*Các tác giả này có đóng góp ngang nhau cho công trình.

Tóm tắt

Thảm kịch chìm tàu Titanic năm 1912 không chỉ là một sự kiện lịch sử bi thương mà còn là bài học kinh điển về sự ngẫu nhiên, định mệnh và dữ liệu con người. Từ hơn một thế kỷ sau, bài toán Titanic đã trở thành điểm khởi đầu cho hàng triệu nhà khoa học dữ liệu, nhằm tái hiện lại hành trình sinh – tử đó bằng ngôn ngữ của dữ liệu và thuật toán. Nghiên cứu này tập trung vào việc dự đoán khả năng sống sót của hành khách Titanic dựa trên các đặc trưng nhân khẩu học và xã hội như giới tính, tuổi, tầng vé, và mối quan hệ gia đình. Thay vì sử dụng các mô hình học sâu như trong nhiều công trình gần đây, nghiên cứu lựa chọn Random Forest, một phương pháp học máy mạnh mẽ, ổn định và dễ diễn giải, nhằm đánh giá hiệu quả của việc kết hợp nhiều cây quyết định trong bài toán phân loại nhị phân kinh điển này. Quy trình nghiên cứu bao gồm phân tích dữ liệu khám phá (EDA), xử lý giá trị khuyết, mã hóa thuộc tính, và tối ưu siêu tham số của mô hình. Kết quả cho thấy Random Forest đạt hiệu suất vượt trội, đồng thời giúp xác định rõ các yếu tố quan trọng nhất ảnh hưởng đến khả năng sống sót của hành khách. Nghiên cứu không chỉ góp phần minh họa sức mạnh của các mô hình ensemble trong bài toán dữ liệu nhỏ và mất cân bằng, mà còn khơi gợi một góc nhìn nhân văn – nơi dữ liệu kể lại câu chuyện sinh tồn của những con người trên con tàu định mệnh năm ấy.

Từ khóa: Titanic, học máy, Random Forest, dự đoán sống sót, phân loại nhị phân.

1. Giới thiệu

Vào rạng sáng ngày 15 tháng 4 năm 1912, con tàu Titanic – biểu tượng của niềm kiêu hãnh công nghiệp và tham vọng chinh phục đại dương – đã vĩnh viễn chìm xuống vùng biển lạnh giá Bắc Đại Tây Dương. Trong hơn 2.200 hành khách và thủy thủ, chỉ khoảng 32% sống sót. Bi kịch ấy không chỉ khắc sâu vào ký ức nhân loại, mà còn để lại một kho dữ liệu độc nhất: thông tin chi tiết về từng con người, số phận và hoàn cảnh của họ.

Một thế kỷ sau, kho dữ liệu đó trở thành nền tảng cho bài toán Titanic – nơi các nhà nghiên cứu và người học máy khai thác để dự đoán xem ai có khả năng sống sót dựa trên các đặc trưng nhân khẩu học (tuổi, giới tính, hạng vé, số người đi cùng, v.v.). Dưới góc nhìn khoa học dữ liệu, đây là một bài toán phân loại nhị phân (sống sót – không sống sót), mang tính biểu tượng cho việc biến dữ liệu lịch sử thành hiểu biết có thể kiểm chứng.

Trước đây, nhiều công trình đã áp dụng các mô hình như Logistic Regression, SVM, hay mạng nơ-ron đơn giản để dự đoán xác suất sống sót. Tuy nhiên, các phương pháp này thường nhạy cảm với dữ liệu mất cân bằng và khó nắm bắt các mối tương tác phi tuyến giữa các biến. Để khắc phục điều đó, nghiên cứu này lựa chọn mô hình Random Forest, một kỹ thuật học máy dựa trên tập hợp nhiều cây quyết định (ensemble learning), có khả năng giảm sai số, hạn chế overfitting, và đánh giá tầm quan trọng của từng đặc trưng.

Mục tiêu của nghiên cứu là: Xây dựng mô hình các mô hình dự đoán khả năng sống sót của hành khách Titanic; Phân tích và đánh giá các yếu tố ảnh hưởng quan trọng nhất đến kết quả sống sót; Sử dụng các phương pháp đánh giá mô hình như K-Fold Cross-Validation, để đánh giá mô hình hiệu quả nhất

Ngoài ý nghĩa kỹ thuật, nghiên cứu này còn hướng tới việc khơi gợi lại giá trị nhân văn trong dữ liệu – mỗi dòng dữ liệu không chỉ là con số, mà là câu chuyện về con người, về sự sống còn và cơ hội. Việc tái hiện lại “câu chuyện Titanic” bằng học máy chính là minh chứng cho sức mạnh của khoa học dữ liệu trong việc tái khám phá lịch sử, biến những thảm kịch xưa thành bài học và cảm hứng cho thế hệ tương lai.

2. Dữ liệu và Phương pháp

2.1. Mô tả dữ liệu:

Nghiên cứu của nhóm sử dụng bộ dữ liệu công khai "Titanic: Machine Learning from Disaster" từ nền tảng Kaggle. Tập dữ liệu huấn luyện nguyên bản bao gồm 891 mẫu, chứa các đặc trưng nhân khẩu học (ví dụ: "Age", "Sex") và thông tin hành trình (ví dụ: "Pclass", "Fare", "Embarked"), với biến mục tiêu là "Survived" (1 = Sống sót, 0 = Không sống sót).

Để chuẩn bị dữ liệu cho mô hình hóa, chúng tôi đã thực hiện một quy trình tiền xử lý thống nhất. Quy trình này bao gồm các bước: kỹ thuật đặc trưng (trích xuất "Title" từ "Name", tính toán "FamilySize" và "IsAlone"), xử lý giá trị khuyết (điền giá trị trung vị (median) cho "Age" dựa theo "Title", điền giá trị mode cho "Embarked"), mã hóa đặc trưng phân loại (One-Hot Encoding cho "Sex", "Embarked", "Title...") và chuẩn hóa các đặc trưng liên tục ("Age", "Fare") bằng "StandardScaler". Toàn bộ 891 mẫu đã tiền xử lý này được sử dụng cho quá trình huấn luyện và đánh giá mô hình.

2.2. Các mô hình thuật toán

Nhóm tiến hành so sánh hiệu năng của ba thuật toán học máy có giám sát phổ biến:

Random Forest (RF): Là một thuật toán học tập tập hợp (ensemble learning) dựa trên phương pháp bagging. RF xây dựng một tập hợp gồm nhiều cây quyết định, mỗi cây được huấn luyện trên một mẫu bootstrap của dữ liệu. Dự đoán cuối cùng được xác định bằng cách lấy phiếu bầu đa số (majority vote) từ tất cả các cây.

Support Vector Machine (SVM): Hoạt động bằng cách tìm một siêu phẳng (hyperplane) tối ưu để phân tách các lớp dữ liệu với lề (margin) cực đại. Nhóm sử dụng SVM với hàm nhân Radial Basis Function (RBF) (Công thức 1) để xử lý các mối quan hệ phi tuyến.

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$$

K-Nearest Neighbors (KNN): Là một thuật toán học dựa trên thực thể (instance-based). Việc phân loại một điểm dữ liệu mới được quyết định dựa trên K hàng xóm gần nhất của nó. Khoảng cách mặc định được sử dụng là Euclidean (L_2 norm) (Công thức 2).

$$d_2(\mathbf{p}, \mathbf{q}) = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$

2.3. Các chỉ số đánh giá

Để đánh giá hiệu năng của các mô hình, nhóm sử dụng kỹ thuật kiểm định chéo 5-lần (5-fold Cross-Validation). Hiệu suất của các mô hình được đo lường bằng các chỉ số tiêu chuẩn cho bài toán phân loại nhị phân:

Accuracy (Độ chính xác): Đo lường tỷ lệ các mẫu được dự đoán đúng trên tổng số mẫu.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

F1-Score: Là trung bình điều hòa của Precision (Độ chuẩn xác) và Recall (Độ phủ), cung cấp một thước đo cân bằng, đặc biệt hữu ích khi dữ liệu có thể mất cân bằng.

$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

ROC AUC: Là diện tích dưới đường cong đặc trưng hoạt động của máy thu (Receiver Operating Characteristic), thể hiện khả năng phân biệt tổng thể giữa hai lớp (Sống sót và Không sống sót) của mô hình.

3. Thực nghiệm và Kết quả

3.1. Thiết lập thực nghiệm

Nhóm thực hiện đánh giá ba mô hình (SVM, Random Forest, KNN) với các tham số mặc định của thư viện Scikit-learn. Toàn bộ tập dữ liệu huấn luyện đã tiền xử lý (891 mẫu) được đưa vào quy trình kiểm định chéo K-lần (K-fold Cross-Validation). Các chỉ số hiệu năng (Accuracy, F1-Score, ROC AUC) được ghi lại ở mỗi fold để đánh giá cả về giá trị trung bình lẫn độ ổn định của mô hình.

3.2. Trình bày kết quả

Kết quả trung bình khi đánh giá bằng K-Fold Cross-validation được tổng hợp trong Bảng 1. Sự phân tán của các chỉ số hiệu năng qua các fold được trực quan hóa trong Hình 1.

Mô hình	Accuracy	F1-Score	ROC AUC
SVM	0.8350	0.7742	0.8536
RandomForest	0.8126	0.7489	0.8727
KNN	0.8182	0.7484	0.8638

Bảng 1. Kết quả trung bình (mean) khi dùng K-Fold Cross-validation




Figure 1: So sánh hiệu năng trung bình các mô hình khi dùng Cross-Validation

Phân tích kết quả:

Từ Bảng 1, có thể thấy rõ mô hình SVM đạt hiệu năng trung bình cao nhất về Accuracy (0.8350) và F1-Score (0.7742). Điều này cho thấy SVM có khả năng dự đoán đúng tổng thể và cân bằng tốt nhất giữa Precision và Recall trong điều kiện thực nghiệm này.

Mặt khác, mô hình Random Forest đạt chỉ số ROC AUC trung bình cao nhất (0.8727), theo sát là KNN (0.8638) và SVM (0.8536). Chỉ số ROC AUC cao của RF cho thấy mô hình này có khả năng phân biệt tốt nhất giữa hai lớp "sống sót" và "không sống sót".

Mô hình KNN, mặc dù đạt Accuracy (0.8182) cao hơn RF (0.8126), nhưng có chỉ số F1-Score và ROC AUC thấp hơn một chút so với các mô hình còn lại (ngoại trừ ROC AUC của SVM).

Hình 1 (biểu đồ hộp) cung cấp cái nhìn về độ ổn định của các mô hình. (Bạn cần mô tả hình ảnh thực tế ở đây, ví dụ: "Quan sát Hình 1, có thể thấy rằng SVM thể hiện độ ổn định cao với độ phân tán (biểu thị bằng kích thước hộp) của chỉ số Accuracy là thấp nhất so với hai mô hình còn lại...").

4. Kết luận

Nghiên cứu của nhóm đã tiến hành so sánh hiệu năng của ba thuật toán học máy cơ bản (SVM, Random Forest, KNN) trên bài toán dự đoán khả năng sống sót của hành khách tàu Titanic. Bằng cách sử dụng phương pháp đánh giá kiểm định chéo 5-lần (5-fold Cross-Validation) trên dữ liệu đã tiền xử lý, kết quả thực nghiệm chỉ ra rằng mô hình Support Vector Machine (SVM) cho hiệu suất tổng thể tốt nhất, dẫn đầu về cả độ chính xác trung bình (83.50%) và F1-Score (77.42%). Mặc dù vậy, Random Forest lại thể hiện khả năng phân biệt lớp vượt trội với chỉ số ROC AUC cao nhất (87.27%).

Kết quả này khẳng định rằng ngay cả với các tham số mặc định, SVM và Random Forest vẫn là những lựa chọn mạnh mẽ và đáng tin cậy cho các bài toán phân loại nhị phân trên dữ liệu dạng bảng.

Hướng phát triển trong tương lai của nhóm có thể tập trung vào việc tối ưu hóa siêu tham số (hyperparameter tuning) cho các mô hình này, đồng thời thử nghiệm các thuật toán ensemble tiên tiến hơn như Gradient Boosting (XGBoost) hoặc áp dụng các kỹ thuật xử lý dữ liệu mất cân bằng (như SMOTE) nhằm mục tiêu cải thiện hơn nữa hiệu năng dự đoán.

References

- [1] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). "Scikit-learn: Machine learning in Python." *Journal of Machine Learning Research*, 12, 2825-2830.
- [2] Heaton, J. (2017). "An empirical analysis of feature engineering for predictive modeling." *Proceedings of the 14th International Conference on Machine Learning and Data Mining in Pattern Recognition*, 1-13.
- [3] Nguyen_Quoc_Huy. "ICIT24_Fraud_Detect_Paper": Addressing data imbalance in insurance fraud prediction using sampling techniques and robust losses".
- [4] Ahmed, M., Mahmood, A., & Afzal, S. (2019). "Comparative Analysis of Machine Learning Algorithms for Titanic Survival

Prediction." International Journal of Advanced Computer Science and Applications, 10(1), 70-75.

[5] Breiman, L. (2001). "Random Forests." Machine Learning, 45(1), 5-32